

BeautyGAN:基于深度生成对抗网络的实例级面部化妆迁移

李婷婷(Tingting Li) *

清华大学清华-伯克利深圳研究所

litt.thu@foxmail.com

youdaoplaceholder0刘思

北京航空航天大学计算机科学与工程
学院数字媒体北京市重点实验室

liusi@buaa.e

du.cn钱瑞河

信息工程研究所
中国科学院

vitochien09@gmail.com

琼燕

商汤科技研究yanqiong@
sensetime.com

o Dong †

SIAT-Sensetime联合实验室, 深圳
先进技术研究院,
中国科学院chao.dong@siat.ac.
cn

朱文武

清华-伯克利深圳研究所, 清华
大学计算机科学与技术系
大学wwzhu@tsinghua.
edu.cn

梁林

中山大学linliang@ieee.
org Cha

摘要

面部化妆转换的目的是在保留面部身份的同时, 将给定的参考化妆脸形象的化妆风格转换为另一种非化妆形象。这样的实例级迁移问题比传统的领域级迁移任务更具挑战性, 尤其是在无法获得成对数据的情况下。化妆风格也不同于全局风格(例如绘画), 因为它由几种局部风格/化妆品组成, 包括眼影、口红、粉底等。对于现有的风格转移方法来说, 提取和转移这种局部和精致的彩妆信息是不可行的。我们通过将全局域级损失和局部实例级损失合并到双输入/输出生成对抗网络(称为BeautyGAN)中来解决这个问题。具体来说, 通过区分生成的图像和域的真实样本的鉴别器来确保域级转移。实例级损失通过单独的局部面部区域上的像素级直方图损失来计算。我们进一步引入感知损失和循环一致性损失来生成高质量的人脸并保持身份。总体目标函数使网络能够通过无监督对抗性学习在实例级学习翻译。我们还建立了一个新的化妆数据集, 该数据集由3834张高分辨率人脸图像组成。大量实验显示

BeautyGAN可以生成视觉上令人愉悦的化妆脸和准确的转移效果。数据和代码可在<http://liusi-group.com/projects/BeautyGAN>上获得。

CCS概念

· 计算方法学→计算机视觉任务;神经网络;无监督学习;

关键词

妆容转移;生成对抗网络

ACM参考格式:

李婷婷、钱瑞河、董超、刘思、闫琼、朱文武、林亮。2018。BeautyGAN:基于深度生成对抗网络的实例级面部化妆迁移。2018年ACM多媒体会议(MM' 18), 2018年10月22日至26日, 韩国首尔。ACM, 美国纽约, 9页。<https://doi.org/10.1145/3240508.3240618>

1 简介

化妆是一种无处不在的改善面部面貌的方式, 用特殊的化妆品, 比如掩盖面部瑕疵的粉底、眼线、眼影和口红。成千上万的化妆品, 从品牌、颜色、使用方法都各不相同, 没有专业人士的建议, 很难找到一款适合自己的妆容风格。虚拟彩妆应用是一个方便的工具, 可以帮助用户从照片中尝试彩妆风格, 比如美图秀秀、TAAZ和DailyMakeover¹。不过, 这些工具都需要用户手动交互, 并且只提供一定数量的固定妆容。在日常生活中, 明星们的妆容总是很美, 这就给出了一些例子供大家参考。彩妆转移提供了一种高效的方式, 帮助用户选择最适合自己的彩妆风格。如图1所示, 彩妆转移(我们方法的结果)可以

*This work was done when Tingting Li and Ruihe Qian were interns at Sensetime. † corresponding author

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than ACM must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.




图1:我们的化妆转移BeautyGAN模型的示例结果。参考图片上的三种化妆风格(上一行)被翻译成三张化妆前的图片(左列)。中间显示的是9张生成的图片。

在不改变面部身份的情况下，将给定的参考面部形象的化妆风格转换为另一张不化妆的面部。

现有的自动化妆转换研究可以分为两类:传统的图像处理方法[11,19,29]，如图像梯度编辑和基于物理的操作，以及基于深度学习的方法，通常建立在深度神经网络[23]上。图像处理方法通常将图像分解为几层(例如，面部结构，颜色，皮肤)，并在将参考面部图像扭曲为未化妆的图像后将每一层传输。基于深度学习的方法[23]采用几个独立的网络分别处理每一种化妆品。几乎所有之前的方法都将化妆风格视为不同组件的简单组合，因此整体输出图像看起来不自然，在组合位置有明显的伪像(见图4)。

最近在图像到图像转换方面的进展，如风格转移[8,9,13]，已经表明，端到端结构作用于整个图像可以产生高质量的结果。然而，在我们的任务中直接应用这些技术仍然是不可行的。面部妆容转移有两个主要特点，与之前的问题不同。1)妆容风格因人而异，需要在实例级进行转移。相反，基于生成式对抗网络(GAN)的典型图像到图像翻译方法[4,12,35]主要用于领域级迁移。例如，CycleGAN[35]实现了两个集合(例如，马和斑马)之间的图像到图像的转换，强调域间差异而忽略域内差异。因此，在我们的问题中使用CycleG

AN倾向于生成给定不同参考面时不变的平均域级风格(见图4)。2)化妆风格超越了全局风格，包括独立的局部风格。具体来说，在传统的风格转移作品中[8,9,13]，风格一般指的是画笔笔触和色彩分布等全局绘画方式。相比之下，妆容风格则更为精致精致，由眼影、口红、粉底等几种局部化妆品组成。每一款化妆品都代表着一种完全不同的风格。因此，在保留各种化妆品的特定特征的同时，很难从整体上提炼出化妆风格。

另一个至关重要的问题是缺乏训练数据。一方面，发布的化妆数据集(见表1)太小，无法训练出足够大的网络，而且面部化妆图像大多是低分辨率/低质量的。另一方面，很难获得一对对齐良好、妆容风格不同的人脸图像。因此，使用配对数据进行监督式学习也是不太可能的。

为了解决上述问题，我们提出了一种名为BeautyGAN的新型双输入/输出生成对抗网络，以在统一的框架中实现化妆风格迁移。它接受化妆和不化妆的脸作为输入，并直接输出转移的结果。不需要额外的预处理/后处理。与CycleGAN[35]类似，该网络首先用几个鉴别器将未化妆的脸转移到化妆域，这些鉴别器将生成的图像与化妆域的真实样本区分开来。在域级转移的基础上，我们通过采用在不同面部区域上计算的像素级直方图损失来实现实例级转移。为了保持面部身份并消除伪影，我们还在总体目标函数中加入了感知损失和周期一致性损失。得益于双输入/输出设计，输入和输出之间的周期一致性可以只用一个发生器实现，在单个前向通道中同时实现化妆和反化妆。而且，在整个训练过程中不需要配对数据。如图1所示，生成的图像外观自然，视觉上令人愉悦，没有可观察到的伪影。

综上所述，主要贡献有三方面：

- (1)我们通过双输入/输出生成对抗网络实现了自动补妆转移。实验证明了转移策略的有效性，生成的结果比最先进的方法质量更高。
- (2)我们通过成功地在局部区域上应用像素级直方图损失来实现实例级风格转移。这种实例级的转移方法可以很容易地推广到其他图像翻译任务中，比如头像的风格转移、图像属性转移等等。
- (3)我们用3834张图片的集合建立了一个新的化妆数据集，该数据集可以在<http://liusi-group.com/projects/BeautyGAN>上获得。

2 相关作品

2.1 化妆研究

最近，与化妆相关的研究引起了越来越多的关注。[31]提出了一种基于位置约束字典学习的面部彩妆检测和卸妆框架。[20]引入了一种对抗网络来生成非化妆图像，用于化妆不变面部验证。妆容转移是另一个吸引人的地方

应用,其目的是在保持源图像身份的同时,从参考图像转移妆容风格。[11]将图像分解为三层,并逐层传递彩妆信息。该方法可以平滑源图像的面部细节,因此[19]引入了另一种图像分解方法。以上的妆容迁移框架都是基于传统的方法,而[23]则以深度学习的方式提出了一种局部化的妆容迁移框架。它将面部化妆分成几个部分,并对每个面部部分进行了不同的方法。使用翘曲和结构保存来合成化妆后的图像。

与前述作品不同的是,我们的网络可以同时实现妆容转移和卸妆。同时,统一的训练过程可以考虑不同地区化妆品之间的关系。此外,端到端网络本身可以学习源图像中输入的化妆品的适应性,从而消除了后处理的需要。

2.2 风格转移

风格转移旨在将不同图像的内容和风格结合起来。为了实现这一目标,[8]提出了一种通过最小化内容和风格重建损失来生成重建图像的方法。为了控制更多的信息,如颜色、尺度和空间位置,[9]提出了一种改进的方法,其中引入了感知因素。上述方法可以产生高质量的结果,但需要大量的计算。[13]提出了一种用于风格迁移的前馈网络,计算量少,质量近似。

2.3 生成对抗网络

生成对抗网络(Generative Adversarial Networks, GANs)是一种生成模型,由判别器和生成器组成。GAN具有生成逼真图像的能力,在计算机视觉任务中得到了广泛的应用。[17]提出了一种用于图像超分辨率的生成式对抗网络。[6]采用条件GAN[25]来解决特定的眼部绘画问题。[27]在合成图像上训练对抗模型,以提高它们的真实感。[34]甚至能够结合用户交互来呈现实时图像编辑,其中利用GAN来估计图像歧管。

2.4 用于图像到图像转换的GAN

现有的大多数图像到图像翻译研究都是为了学习一种从源域到目标域的映射。最近,将GAN应用于这一领域也有一些很有前景的工作[4,12,35]。[12]提出了一个所谓的pix2pix框架,它可以从标签地图合成图像,从边缘图像重建物体。为了解决缺乏用于训练的配对图像的问题,[22]提出了一个模型,该模型的生成器以权重共享约束为界,以学习联合分布。[35][14]提出循环一致性损失来正则化输入和翻译图像之间的关键属性。StarGAN[4]甚至解决了单个生成器内多个域之间的映射问题。[15]特别介绍了一种基于GAN的图像属性传输编码器。

3 我们的方法:beautygan

我们的目标是在实例级实现参考化妆图像和非化妆图像之间的面部化妆转换。考虑两个数据集, $A \wedge RH \times W \times 3$ 指的是非化妆图像域, $B \wedge RH \times W \times 3$ 指的是开着各种妆容风格的化妆图像域。我们同时学习两个域之间的映射,表示为 $G: A \times B \rightarrow B \times A$,其中“ $\times$ ”表示笛卡尔积。也就是说,给定两幅图像作为输入:源图像 $I_{src} \in a$ 和参考图像 $I_{ref} \in B$,期望网络生成化妆后图像 $I_{srcB} \in B$ 和化妆后图像 $I_{refA} \in a$,表示为 $(I_{srcB}, I_{refA}) = G(I_{src}, I_{ref})$ 。 I_{srcB} 综合化妆风格参考的同时又保留了 I_{src} 的面部特征, I_{refA} 实现了 I_{ref} 的卸妆。最根本的问题是如何学习实例级的对应关系,保证结果图像 I_{srcB} 和参考图像 I_{ref} 的拼接风格一致。需要注意的是,这里没有用于训练的配对数据。

为了解决这个问题,我们引入了像素级直方图损失作用于不同的化妆品。此外,还采用了感知损失来维持人脸的身份和结构。然后,我们可以在不改变面部结构的情况下,将准确的妆容转移到源图像上。所提出的方法基于生成式对抗网络[10],方便地将所有损失项集成到一个完整的目标函数中。对抗损失有助于生成视觉上令人愉悦的图像,并细化不同化妆品之间的相关性。损失函数和网络架构的细节如下图所示。

3.1 完整目标

如图2所示,整个框架由一个生成器 G 和两个鉴别器组成: DA, DB 。在公式 $(I_{srcB}, I_{refA}) = G(I_{src}, I_{ref})$ 中, G 接受 $I_{src} \in A$ 和 $I_{ref} \in B$ 两幅图像作为输入,生成两幅翻译后的图像作为输出, $I_{srcB} \in B$ 和 $I_{refA} \in A$ 。

我们首先给出了只包含对抗损失的 DA 和 DB 的目标函数。 D_A 将生成的图像 I_{refA} 与集合 A 中的真实样本区分开来,给出如下:

$$\begin{aligned} \mathcal{L}_{DA} = & \mathbb{E}_{I_{src}} [\log D_A(I_{src})] \\ & + \mathbb{E}_{I_{src}, I_{ref}} [\log(1 - D_A(I_{refA}))]. \end{aligned} \quad (1)$$

同样, DB 的目的是将生成图像 I_{srcB} 与集合 B 中的真实样本区分开来,由下式给出:

$$\begin{aligned} \mathcal{L}_{DB} = & \mathbb{E}_{I_{ref}} [\log D_A(I_{ref})] \\ & + \mathbb{E}_{I_{src}, I_{ref}} [\log(1 - D_A(I_{srcB}))]. \end{aligned} \quad (2)$$

生成器 G 的完整目标函数包含四种类型的损失:对抗性损失、周期一致性损失、感知损失和补强约束损失,

$$\mathcal{L}_G = \alpha \mathcal{L}_{adv} + \beta \mathcal{L}_{cyc} + \gamma \mathcal{L}_{per} + \mathcal{L}_{makeup}, \quad (3)$$

其中 α, β, γ 是控制每一项相对重要性的加权因子。 G 的对抗损失积分了两个项: LDA 和 LDB 作为

$$\mathcal{L}_{adv} = \mathcal{L}_{DA} + \mathcal{L}_{DB}. \quad (4)$$




图2:提出的BeautyGAN框架。上面的管道显示了整个系统。 G 接受两个图像作为输入:不化妆图像 I_{src} , 参考化妆图像 I_{ref} , 并产生两个输出:转移的化妆图像 I_{src}^B , 反化妆图像 I_{ref}^{rec} 。将生成的图像输入同一个 G , 建立重建结果: I_{src}^{rec} , I_{ref}^{rec} 。有4个

训练 G 的损失术语:周期一致性损失、感知损失、对抗损失(表示为 D_A 和 D_B)和弥补损失。下面的管道显示了弥补损失的细节。它由三个局部直方图损失项组成, 分别作用于脸部、眼影和嘴唇。我们首先利用人脸解析模型对 I_{src} , I_{ref} , I_{src}^B 的每个化妆品区域进行分离。然后, 对于每个区域, 我们使用 I_{src} 和 I_{ref} 之间的直方图匹配, 获得一个直方图重新映射面部区域作为地面真值。局部损失项计算这样的地面真值与相应的 I_{src}^B 修饰区域之间的像素级差。

注意, 生成器 G 和鉴别器 D_A, D_B 玩最小最大游戏, 其中 G 试图最小化对抗损失, 鉴别器 D_A, D_B 的目标是最大化相同的损失函数。剩下的三种损失将在后面的章节中详细介绍。

3.2 Domain-Level Makeup Transfer

我们利用领域级化妆转移作为实例级化妆转移的基础。由于双输入/输出架构, 所提出的网络可以在一个生成器内同时学习两个域之间的映射。输出图像需要保留人脸身份和背景信息作为输入图像。为了满足这两个约束, 我们分别施加了感知损失和周期一致性损失。

感知损失不是直接测量像素级欧几里得距离之间的差异, 而是计算深度卷积网络提取的高级特征之间的差异。在本文中, 我们使用在ImageNet数据集上预训练的16层VGG网络。对于图像 x , $F_l(x)$ 表示VGG上第 l 层

对应的特征映射, 其中 $F_l \in \mathbb{R}^{C_l \times H_l \times W_l}$ 。 C_l 为特征图的个数, H_l 和 W_l 分别为每个特征图的高度和宽度。因此, 输入图像 I_{src} , I_{ref} 与输出图像 I_{src}^B , I_{ref}^{rec} 之间的感知损失表示为:

$$\mathcal{L}_{per} = \frac{1}{C_l \times H_l \times W_l} \sum_{ijk} E_l \quad (5)$$

$$E_l = [F_l(I_{src}) - F_l(I_{src}^B)]_{ijk}^2 + [F_l(I_{ref}) - F_l(I_{ref}^{rec})]_{ijk}^2, \quad (6)$$

其中 F_{ijkl} 是第 l 层在 (j,k) 位置的第 i 个滤波器的激活。

为了保持背景信息, 我们还引入了周期一致性损失。当输出图像传入生成器时, 它应该生成与原始输入图像一样接近的图像。这个过程可以表示为

$$(I_{src}, I_{ref}) \rightarrow G(I_{src}, I_{ref}) \rightarrow G(G(I_{src}, I_{ref})) \approx (I_{src}, I_{ref}). \quad (7)$$

损失函数表示为

$$\mathcal{L}_{cyc} = \mathbb{E}_{I_{src}, I_{ref}} [\text{dist}(I_{src}^{rec}, I_{src}) + \text{dist}(I_{ref}^{rec}, I_{ref})], \quad (8)$$

where $(I_{src}, I_{ref}) = G(G(I_{src}, I_{ref}))$ 。距离函数 $\text{dist}(\cdot)$ 可选为 $L1$ 范数、 $L2$ 范数或其他指标。

3.3 实例级化妆转移

为了进一步鼓励网络学习实例级化妆迁移，有必要增加对化妆风格一致性的约束。我们观察到，面部妆容可以在视觉上被识别为颜色分布。无论是口红、眼影还是粉底，化妆过程主要可以理解为颜色的变化。在调查[7]中可以找到各种各样的调色方法。我们采用直方图匹配(HM)，这是一种简单的方法，并在像素级引入了额外的直方图损失，这限制了输出图像 I_{srcB} 和参考图像 I_{ref} 在构图风格上是相同的。

直方图损失。如果我们直接对两幅图像的像素级直方图采用MSE损失，由于指标函数的存在，梯度将为零，因此对优化过程没有贡献。因此，我们采用直方图匹配策略，提前生成一个ground truth remapping图像。假设我们要计算原始图像 x 和参考图像 y 之间像素上的直方图损失，我们首先要对 x 和 y 进行直方图匹配，得到一个与 y 具有相同颜色分布但仍然保留与 x 相同内容信息的重映射图像 $HM(x, y)$ 。得到 $HM(x, y)$ 后，利用 $HM(x, y)$ 和 x 之间的MSE损失，然后反向传播梯度进行优化是方便的。

人脸解析。我们没有在整个图像上利用直方图损失，而是将化妆风格分成三个重要的组成部分

-口红，眼影，粉底。[23]等最先进的化妆方法也将这三种成分作为化妆的代表。然后我们对每个部分应用局部直方图损失。原因有两层。第一，背景和头发中的像素与妆容没有关系。如果我们不把它们分开，就会扰乱正确的色彩分布。其次，脸谱超越了一种全球风格，而是不同化妆品区域的几种独立风格的集合。在这个意义上，我们采用[32]中的人脸解析模型，得到的人脸引导掩码为 $M = FP(x)$ 。对于每个输入图像 x ，预训练的人脸解析模型会生成一个索引掩码 M ，表示几个面部位置，包括嘴唇、眼睛、面部皮肤(对应于粉底)、头发、背景等。最后，对于每个 M ，我们跟踪不同的标签，生成三个对应的二值掩模，代表化妆品的空间性： M_{lip} , M_{eye} , M_{face} 。需要注意的是，眼影没有在 M 上标注，因为化妆前的图像没有眼影。但我们期望结果图像 I_{srcB} 具有与参考图像 I_{ref} 相似的眼影颜色和形状。根据眼罩 M_{eye} ，我们计算出两个包围眼影的矩形区域，然后排除眼部区域，以及中间的一些头发和眉毛区域。这样我们就可以创建一个特定的二值蒙版，表示为眼影的 M_{shadow} 。

化妆损失。整体的妆容损失是由嘴唇、眼影和面部区域的三个局部直方图损失综合起来的，



图3:来自MT数据集的样本。未化妆和化妆的图像分别显示在上行和下行中。

表1:与已发布的化妆数据集对比。

Dataset	Subjects	Images per subject	Total number of images
YMU[2]	151	4	604
VMU[5]	51	4	204
MIW[1]	125	1-2	154
MIFS[3]	214	4 or 2	642
Ours(MT)	3000+	1-2	3834

分别为:

$$\mathcal{L}_{makeup} = \lambda_l \mathcal{L}_{lips} + \lambda_s \mathcal{L}_{shadow} + \lambda_f \mathcal{L}_{face}, \quad (9)$$

其中 λ_l , λ_s , λ_f 是权重因子。我们将图像与其对应的二值掩模相乘，并处理结果图像 I_{srcB} 与参考图像 I_{ref} 之间的空间直方图匹配。形式上，我们将局部直方图损失定义为

$$\mathcal{L}_{item} = \|I_{src}^B - HM(I_{src}^B \circ M_{item}^1, I_{ref} \circ M_{item}^2)\|_2. \quad (10)$$

$$M^1 = FP(I_{src}^B) \quad (11)$$

$$M^2 = FP(I_{ref}) \quad (12)$$

在这里， $\circ$ 表示元素明智的乘法，项 M 在 $\{lips, shadow, f_{face}\}$ 的集合中。

4 数据收集

我们收集了一个新的面部化妆数据集，共包含3834张女性图像，其中非化妆图像1115张，化妆图像2719张。我们把这个数据集称为化妆转移(MT)数据集。它包括种族、姿势、表情和背景杂波的一些变化。集结了大量的妆容风格，包括烟熏妆、浮华妆、复古妆、韩式妆、日式妆，从淡雅到厚重都有。具体来说，还有一些裸妆的形象，至于方便，都被归入了非彩妆类。

最初的数据是从网站上抓取的。我们手动移除光照条件不好的低分辨率图像。然后利用68个地标对保留的图像进行人脸对齐。根据两个眼睛的位置，我们将它们转换成相同的

空间大小 256×256 。在3834张图片中，我们随机抽取100张非化妆图片和250张化妆图片进行测试。剩下的图像分为训练集和验证集。

与其他发布的化妆数据集相比，MT是最大的化妆数据集。现有的化妆数据集大多由不超过1000张的图像组成。它们通常为一个主题组装成对的图像：化妆前图像和化妆后图像对。虽然在这样的成对图像中获得了相同的对象，但它们在视图上有差异：姿势，表情甚至照明。一般用于研究化妆对人脸识别的影响，不适用于化妆转移任务。MT数据集包含多种化妆风格和3000多个主题。化妆数据集之间的详细对比列于表1。图3展示了MT的示例。

5 实验

在本节中，我们描述了网络架构和训练设置。所有的实验都使用我们发布的相同的MT数据集。我们从定性和定量的角度比较了我们的方法和其他一些基线的性能。并且我们进一步对BeautyGAN的组成部分进行了深入的分析。

5.1 实现细节

网络架构。我们设计的generatorG有两个输入和两个输出。具体来说，该网络分别包含两个独立的具有卷积的输入分支。在中间，我们将这两个分支连接在一起，并将它们馈送到几个残差块中。之后，输出的特征图将被转置卷积的两个独立分支上采样，以生成两个结果图像。注意，分支在层内不共享参数。我们也使用实例规范化[30]forG。至于鉴别器DA和DB，我们利用相同的 70×70 PatchGANs[18]，它将局部重叠的图像补丁分类为真实或虚假。

Training Details。为了稳定训练过程并生成高质量的图像，我们应用了两个额外的训练策略。首先，受[35]的启发，我们将对抗性损失中的所有负对数似然目标替换为最小二乘损失[24]。例如，然后将等式1定义为如下，即等式2和等式4：

$$\mathcal{L}_{DA} = \mathbb{E}_{I_{src}} [(D_A(I_{src}) - 1)^2] + \mathbb{E}_{I_{src}, I_{ref}} [D_A(I_{ref}^A)^2]. \quad (13)$$

其次，我们引入谱归一化[26]来稳定训练鉴别器。它计算量轻，易于合并，满足Lipschitz约束 $\sigma(W) = 1$ ：

$$W_{SN}(W) := \frac{W}{\sigma(W)}, \quad (14)$$

其中 $\sigma(W)$ 是W的谱范数，记为：

$$\sigma(w) := \max_{h: \|h\|_2=1} \|Wh\|_2 = \max_{\|h\|_2 \leq 1} \|Wh\|_2, \quad (15)$$

这里， h 是每一层的输入。

对于所有的实验，我们通过训练用于人脸分割的PSPNet[33]获得不同面部区域上的带标注标签的掩码。采用VGG16[28]网络的 $relu_4_1$ 特征层进行身份保持。这种VGG16是在ImageNet上

进行预训练的，在整个训练过程中参数都是固定的。方程3和9中的参数为： $\alpha = 1$ ， $\beta = 10$ ， $\gamma = 0.005$ ， $\lambda_l = 1$ ， $\lambda_s = 1$ ， $\lambda_f = 0.1$ 。我们使用Adam[16]从头开始训练网络，学习率为0.0002，批大小为1。

5.2 Baselines

Digital Face Makeup[11]是早期的彩妆转移作品，应用了传统的图像处理方法。

DTN[23]是最先进的彩妆转印作品。它提出了一个深度本地化的彩妆转移网络，可以独立转移不同的化妆品。

深度图像类比[21]是最近的一项工作，它实现了跨两个语义相关图像的视觉属性转移。它采用图像类比来匹配从深度神经网络中提取的特征。我们将其应用于化妆转移任务进行比较。

CycleGAN[35]是一个具有代表性的无监督图像到图像的翻译工作。为了适应化妆转换任务，我们将其中的生成器修改为两个分支作为输入，但保持所有其他架构和设置不变。

Style Transfer[13]是一个相关的工作，它训练了一个前馈网络，用于从各自的图像中合成风格和内容信息。我们采用非化妆图像作为内容，参考化妆图像作为风格进行实验。

5.3 对比基线

定性评价。如图4所示，我们展示了与基线的定性比较结果。我们观察到，尽管Guo等人的[11]生成了化妆后的图像，但结果都有可见的伪影。看起来就像是在没化妆的脸上贴了一个假面具。面部和眼睛轮廓周围出现不匹配问题。一些不正确的细节被转移，比如第二排和第四排的黑色眼影被转移成蓝色。Liu等[23]独立转移不同的化妆品，因此，它显示眼部和唇部周围的对齐伪影。粉底和眼影也没有正确转移。风格转移[13]生成的图像会引入颗粒状伪影，从而降低图像质量。它通常会像画笔触一样转移全局风格，因此对于精致的化妆风格转移是不可行的。与上述方法相比，CycleGAN[35]可以产生相对逼真的图像。不过，妆容风格与参考文献并不一致。Liao等人的[21]产生了与参考相似的化妆风格的输出，并显示出自然的结果。然而，它传递的不仅仅是面部妆容，还有参考图像中的其他特征。比如，第三张图片将背景色从黑色改为灰色，第四张图片将发色改为头发颜色，所有图片都将瞳孔颜色修改为与参考图片相似。此外，它还转移了比参考文献更轻的化妆风格，尤其是在口红和眼影上。

与基线相比，无论对比眼影、口红还是粉底，我们的方法都能生成高质量的图像，并显示出最准确的化妆风格。例如，在第二行中，只有我们的结果转移了参考图像的深色眼影。结果还表明，BeautyGAN保留了其他与化妆无关的成分，如头发、衣服和背景，就像原始的素颜图像一样。在图5中，我们进行了放大




图4:BeautyGAN与基线的定性比较。前两列分别为非化妆图片和参考图片。其余各列每一行显示的是不同方法的彩妆转移结果。




图5:放大眼妆和口红转移的表现。

在表演中对眼妆和口红转移进行了更好的展示对比。在补充文件中展示了更多的结果。

定量比较。为了对BeautyGAN进行定量评价，我们对84名志愿者进行了用户研究。我们随机选择10张不化妆的测试图片和20张化妆的测

试图片，这将得到每一种化妆转移方法的化妆后结果 10×20 。比较了两个具有代表性的基线:Liao *et al.*[21]和Liu *et al.*[23]。每次，我们都会呈现5张图片，包括一张不化妆的图片，一张化妆的图片作为参考，以及三张不同方法生成的随机洗牌的化妆转移图片。参与者被要求给出排序顺序为




图6:消融研究结果。前两列分别为非化妆图像和参考图像。其余各列每一行分别为A、B、C、D、e五个实验的化妆转移结果。不同的实验设置如表2所示。

表2:消融研究设置

Setup	$\mathcal{L}_{per}$	$\mathcal{L}_{face}$	$\mathcal{L}_{eye-shadow}$	$\mathcal{L}_{lips}$
A		✓	✓	✓
B	✓			
C	✓	✓		
D	✓	✓	✓	
E	✓	✓	✓	✓

表3:用户研究结果。

Methods	Rank 1	Rank 2	Rank 3
Liu[23]	4.25%	10.78%	84.97%
Liao[21]	33.91%	46.03%	20.06%
Ours	61.84%	27.56%	10.59%

三张生成的图像，基于质量、真实感和妆容风格相似性。排名1代表最好的妆容转移表现，排名3代表最差的妆容转移表现。

表3显示了结果。对于每种方法，我们将投票归一化，并获得三个排名顺序的百分比。BeautyGAN排名第一的结果为61.84%，而Liao等人的结果为33.91%，Liu等人的结果为4.25%。此外，BeautyGAN在第3列上的百分比最小。我们观察到，BeautyGAN的投票多为1级，Liao等人的投票多为2级，Liu等人的投票多为3级。用户研究表明，我们的方法比其他基线表现得更好。

5.4 BeautyGAN成分分析

为了研究每个组成部分在总体目标函数中的重要性(Eqn3)，我们进行了消融研究。我们主要分析了感知损失项(Eqn. 5)和弥补损失项(Eqn. 9)的影响，因此一直在对抗性和周期一致性损失的情况下进行实验。表2显示了设置，图6展示了结果。

在实验A中，我们从Eqn中去掉了感知损失项。在这种情况下，结果都是假的图像，就像两个输入

在像素上扭曲和合并。相反，其他包含感知损失项的实验表明，非化妆脸的身份得到了维持。因此，这表明感知损失有助于保持图像身份。

实验B、C、D、E是为研究化妆损失项而设计的，化妆损失项由作用于不同化妆区域的三个局部直方图损失组成： $\mathcal{L}_{face}$ 、 $\mathcal{L}_{shadow}$ 、 $\mathcal{L}_{lips}$ 。在实验B中，我们直接从Eqn中去除补妆损失。我们发现生成的图像在肤色和口红上有轻微的修改，但没有从参考图像中转移化妆风格。然后，我们依次在实验C、D、e上添加 $\mathcal{L}_{face}$ 、 $\mathcal{L}_{shadow}$ 和 $\mathcal{L}_{lips}$ 。C列显示了从参考图像成功转移基础的结果。在粉底转移的基础上，实验D在其中加入眼影约束 $\mathcal{L}_{shadow}$ 。我们观察到局部眼妆也被转移了。E列是在整体妆容损失的情况下训练的结果。它表明，与d列相比，口红被额外转移。综上所述，化妆损失对于实例级化妆转移是必要的。妆损的三个术语分别对粉底、眼影和口红转移起作用。

6 结论与未来工作

在本文中，我们提出了一个双输入/输出的BeautyGAN用于实例级的面部化妆传输。通过一个发电机，BeautyGAN可以在一个向前通道中同时实现化妆和反化妆。我们引入像素级直方图损失来约束化妆风格的相似性。我们采用了感知损失和循环一致性损失来保持身份。实验结果表明，我们的方法可以比现有方法获得显著的性能增益。

国家重点基础研究计划项目(No. 2015CB352300)、国家自然科学基金重大项目(No. 2015CB352300)资助。国家自然科学基金项目(No. U1536203, 61572493);Y6Z0021102, 国家科学基金项目;Y7Z0241102), ccf-腾讯开放研究基金及中国科学院国际合作计划(172644KYSB20160033)。

参考文献

- [1] Cunjian Chen, Antitza Dantcheva, and Arun Ross. 2013. Automatic facial makeup detection with application in face recognition. In *Biometrics (ICB), 2013 International Conference on*. IEEE, 1–8.
- [2] Cunjian Chen, Antitza Dantcheva, and Arun Ross. 2016. An ensemble of patch-based subspaces for makeup-robust face recognition. *Information fusion* 32 (2016), 80–92.
- [3] Cunjian Chen, Antitza Dantcheva, Thomas Swearingen, and Arun Ross. 2017. Spoofing faces using makeup: An investigative study. In *Identity, Security and Behavior Analysis (ISBA), 2017 IEEE International Conference on*. IEEE, 1–8.
- [4] Yunje Choi, Minje Choi, Munyoung Kim, Jung-Woo Ha, Sunghun Kim, and Jaegul Choo. 2017. StarGAN: Unified Generative Adversarial Networks for Multi-Domain Image-to-Image Translation. *arXiv preprint arXiv:1711.09020* (2017).
- [5] Antitza Dantcheva, Cunjian Chen, and Arun Ross. 2012. Can facial cosmetics affect the matching accuracy of face recognition systems?. In *Biometrics: Theory, Applications and Systems (BTAS), 2012 IEEE Fifth International Conference on*. IEEE, 391–398.
- [6] Brian Dolhansky and Cristian Canton Ferrer. 2017. Eye In-Painting with Exemplar Generative Adversarial Networks. *arXiv preprint arXiv:1712.03999* (2017).
- [7] Hasan Sheikh Faridul, Tania Pouli, Christel Chamaret, Jürgen Stauder, Alain Trémeau, Erik Reinhard, et al. 2014. A Survey of Color Mapping and its Applications. *Eurographics (State of the Art Reports)* 3 (2014).
- [8] Leon A Gatys, Alexander S Ecker, and Matthias Bethge. 2015. A neural algorithm of artistic style. *arXiv preprint arXiv:1508.06576* (2015).
- [9] Leon A Gatys, Alexander S Ecker, Matthias Bethge, Aaron Hertzmann, and Eli Shechtman. 2017. Controlling perceptual factors in neural style transfer. In *IEEE Conference on Computer Vision and Pattern Recognition*.
- [10] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. 2014. Generative adversarial nets. In *Advances in neural information processing systems*. 2672–2680.
- [11] Dong Guo and Terence Sim. 2009. Digital face makeup by example. In *Computer Vision and Pattern Recognition, 2009. IEEE Conference on*. IEEE, 73–79.
- [12] Phillip Isola, Jun-Yan Zhu, Tinghui Zhou, and Alexei A Efros. 2016. Image-to-image translation with conditional adversarial networks. *arXiv preprint arXiv:1611.07004* (2016).
- [13] Justin Johnson, Alexandre Alahi, and Li Fei-Fei. 2016. Perceptual losses for real-time style transfer and super-resolution. In *European Conference on Computer Vision*. Springer, 694–711.
- [14] Taeksoo Kim, Moonsu Cha, Hyunsoo Kim, Jungkwon Lee, and Jiwon Kim. 2017. Learning to discover cross-domain relations with generative adversarial networks. *arXiv preprint arXiv:1703.05192* (2017).
- [15] Taeksoo Kim, Byoungjip Kim, Moonsu Cha, and Jiwon Kim. 2017. Unsupervised visual attribute transfer with reconfigurable generative adversarial networks. *arXiv preprint arXiv:1707.09798* (2017).
- [16] Diederik P Kingma and Jimmy Ba. 2014. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980* (2014).
- [17] Christian Ledig, Lucas Theis, Ferenc Huszar, Jose Caballero, Andrew Cunningham, Alejandro Acosta, Andrew Aitken, Alykhan Tejani, Johannes Totz, Zehan Wang, et al. 2016. Photo-realistic single image super-resolution using a generative adversarial network. *arXiv preprint arXiv:1609.04802* (2016).
- [18] Chuan Li and Michael Wand. 2016. Precomputed real-time texture synthesis with markovian generative adversarial networks. In *European Conference on Computer Vision*. Springer, 702–716.
- [19] Chen Li, Kun Zhou, and Stephen Lin. 2015. Simulating makeup through physics-based manipulation of intrinsic image layers. In *IEEE Conference on Computer Vision and Pattern Recognition*. 4621–4629.
- [20] Yi Li, Lingxiao Song, Xiang Wu, Ran He, and Tieniu Tan. 2017. Anti-Makeup: Learning A Bi-Level Adversarial Network for Makeup-Invariant Face Verification. *arXiv preprint arXiv:1709.03654* (2017).
- [21] Jing Liao, Yuan Yao, Lu Yuan, Gang Hua, and Bing Kang. 2017. Visual attribute transfer through deep image analogy. *ACM Transactions on Graphics (TOG)* 36, 4 (2017), 120.
- [22] Ming-Yu Liu and Oncl Tuzel. 2016. Coupled generative adversarial networks. In *Advances in neural information processing systems*. 469–477.
- [23] Si Liu, Xinyu Ou, Ruihe Qian, Wei Wang, and Xiaochun Cao. 2016. Makeup like a superstar: deep localized makeup transfer network. In *the Association for the Advance of Artificial Intelligence*. AAAI Press, 2568–2575.
- [24] Xudong Mao, Qing Li, Haoran Xie, Raymond Y. K. Lau, and Zhen Wang. 2016. Multi-class Generative Adversarial Networks with the L2 Loss Function. *CoRR* abs/1611.04076 (2016). [arXiv:1611.04076](http://arxiv.org/abs/1611.04076) <http://arxiv.org/abs/1611.04076>
- [25] Mehdi Mirza and Simon Osindero. 2014. Conditional generative adversarial nets. *arXiv preprint arXiv:1411.1784* (2014).
- [26] Takeru Miyato, Toshiki Kataoka, Masanori Koyama, and Yuichi Yoshida. 2018. Spectral normalization for generative adversarial networks. *arXiv preprint arXiv:1802.05957* (2018).
- [27] Ashish Shrivastava, Tomas Pfister, Oncl Tuzel, Josh Susskind, Wenda Wang, and Russ Webb. 2016. Learning from simulated and unsupervised images through adversarial training. *arXiv preprint arXiv:1612.07828* (2016).
- [28] K. Simonyan and A. Zisserman. 2014. Very Deep Convolutional Networks for Large-Scale Image Recognition. *CoRR* abs/1409.1556 (2014).
- [29] Wai-Shun Tong, Chi-Keung Tang, Michael S Brown, and Ying-Qing Xu. 2007. Example-based cosmetic transfer. In *Computer Graphics and Applications, 2007. PG'07. 15th Pacific Conference on*. IEEE, 211–218.
- [30] Dmitry Ulyanov, Andrea Vedaldi, and Victor S. Lempitsky. 2016. Instance Normalization: The Missing Ingredient for Fast Stylization. *CoRR* abs/1607.08022 (2016). [arXiv:1607.08022](http://arxiv.org/abs/1607.08022) <http://arxiv.org/abs/1607.08022>
- [31] Shuyang Wang and Yun Fu. 2016. Face Behind Makeup. In *the Association for the Advance of Artificial Intelligence*. 58–64.
- [32] Zhen Wei, Yao Sun, Jinqiao Wang, Hanjiang Lai, and Si Liu. 2017. Learning Adaptive Receptive Fields for Deep Image Parsing Network. In *IEEE Conference on Computer Vision and Pattern Recognition*. 2434–2442.
- [33] Hengshuang Zhao, Jianping Shi, Xiaojuan Qi, Xiaogang Wang, and Jiaya Jia. 2017. Pyramid scene parsing network. In *IEEE Conference on Computer Vision and Pattern Recognition*. 2881–2890.
- [34] Jun-Yan Zhu, Philipp Krähenbühl, Eli Shechtman, and Alexei A Efros. 2016. Generative visual manipulation on the natural image manifold. In *European Conference on Computer Vision*. Springer, 597–613.
- [35] Jun-Yan Zhu, Taesung Park, Phillip Isola, and Alexei A Efros. 2017. Unpaired image-to-image translation using cycle-consistent adversarial networks. *arXiv preprint arXiv:1703.10593* (2017).